Universidad Alfonso X el Sabio
Grado en Ingeniería Informática
Inteligencia Artificial · Prof. Jacinto

Marketing Mix Model para K-Moda

¿Cuánto de nuestras ventas se debe a la publicidad?
¿Y cómo repartir mejor el presupuesto?

Alejandro Barreche Ruiz
Curso 2025-2026

Índice

1. Introducción 1

2. ETL · Construcción de la tabla maestra 3

3. Data Understanding · Explorando los datos 6

4. Data Preparation · Del euro al coeficiente 11

5. Modeling · Ajuste y validación 16

6. Evaluation · Atribución, escenarios y sensibilidad 20

7. Dashboard · El modelo en manos del comité 25

8. Conclusiones y recomendaciones 27

1 | Introducción

K-Moda es una cadena nacional de moda con presencia en diez ciudades, dos canales de venta (tienda y online) y una inversión publicitaria repartida entre ocho medios distintos. La pregunta que mueve este proyecto es sencilla, aunque la respuesta no lo sea:

> *"De cada euro que vendemos, ¿cuánto se debe al marketing? Y si queremos vender más el año que viene, ¿dónde conviene invertir ese presupuesto?"*

1.1 Objetivo

Construir un **Marketing Mix Model** (MMM) que responda dos preguntas:

1. **Atribución**: qué porcentaje de las ventas semanales se explica por la inversión publicitaria, y cuánto proviene de la marca, la recurrencia y el SEO (lo que llamamos *base orgánica*).
2. **Simulación**: dado un presupuesto anual, ¿qué combinación entre canales maximiza las ventas, y con qué nivel de riesgo?

El entregable final es doble: (i) un modelo estadístico reproducible, y (ii) un panel interactivo (*dashboard*) que permite al equipo directivo explorar escenarios sin conocer el código.

1.2 Resumen ejecutivo

- Sobre 258 semanas (2020–2024) y 758.1 M€ de ventas acumuladas, el modelo atribuye al marketing el **91.8 %** del total predicho. Este número es una *cifra-modelo* obtenida del contrafactual "apagar todos los canales desde 2020" — se discute honestamente en la sección de evaluación.
- Cuatro grupos de canales: **Performance**, **Branding Digital**, **Offline Medios** y **Propios y Exterior**. El orden por ROI es claro: **Propios y Exterior 25.7**×, Offline Medios 15.3×, Branding Digital 8.5×, Performance 6.0×.
- El modelo generaliza bien fuera de muestra: R^2_{test} **= 0.65**, **MAPE test = 12.2 %**, dentro del rango sano para un MMM (8–20 %). El test placebo añade un ΔR^2 = +0.535 sobre el modelo con ruido → señal real.
- Una reasignación del **30 % del presupuesto de Performance a Propios y Exterior** (DO SOMETHING) proyecta *lift* positivo sin aumentar el gasto total. Es la recomendación operativa.

1.3 Metodología en una página

El pipeline se divide en cinco bloques, cada uno documentado en su propia sección:

Etapa	Qué hace
1. ETL	Une las siete tablas de origen (ventas, pedidos, inversión, calendario, tráfico, clientes, productos) en una única tabla semanal nacional.
2. Data understanding	Explora estacionalidad, correlaciones, huecos y calidad de la señal antes de modelar.
3. Data preparation	Agrupa los 8 canales en 4 grupos según mecánica de respuesta, aplica *adstock* con α diferenciado y saturación logarítmica.
4. Modeling	Ajusta una regresión ElasticNet con restricción de coeficientes positivos, valida con *hold-out* estratificado y cuantifica incertidumbre con *bootstrap* por bloques.
5. Evaluation	Descompone ventas en base vs. marketing, simula escenarios y construye el dashboard ejecutivo.

1.4 A quién va dirigido este informe

Este documento está escrito para un lector directivo: **no se presupone background estadístico**. Cada decisión técnica se justifica en términos de negocio, y las fórmulas se limitan a lo imprescindible. Las secciones más técnicas (*Data Preparation* y *Modeling*) incluyen cajas de *"Decisión técnica"* que pueden saltarse sin perder el hilo.

2 | ETL · Construcción de la tabla maestra

KEY TAKEAWAY

Siete tablas de origen, casi 1.5 GB de datos crudos, se transforman en **una única tabla semanal nacional** con 258 filas (semanas) y las variables que alimentan el modelo. Todo parte de aquí: si la tabla está mal, el modelo está mal.

2.1 Contexto

El caso nos entrega siete archivos CSV en la carpeta `data/lake/`. Los más pesados son `pedidos.csv` (∼540 MB) y `ventas_lineas.csv` (∼965 MB) — millones de filas a nivel línea de pedido. El modelo, en cambio, necesita **semanas**, no líneas. El trabajo del ETL es agregar, limpiar y unir.

2.2 Decisiones clave

DECISIÓN TÉCNICA

Granularidad: *semanal nacional*. Todas las fechas se normalizan al lunes ISO de su semana, y las diez ciudades se suman. Se pierde detalle geográfico, pero se gana una serie temporal limpia de 258 semanas alineadas con el gasto publicitario.

DECISIÓN TÉCNICA

Target (Y_t): `venta_neta_total_eur`, la suma semanal de `venta_neta_sin_iva_eur` de `ventas_lineas`. Es la variable que el modelo intentará explicar.

DECISIÓN TÉCNICA

Ticket medio: se calcula desde `pedidos.csv`, no desde líneas. Calcularlo sobre líneas infla el ticket, porque cada pedido tiene varias líneas pero un solo cliente y un solo carrito.

DECISIÓN TÉCNICA

Tráfico excluido del modelo: las métricas de `trafico_tienda_web_diario.csv` (visitas web, tráfico tienda) son *mediadores*: están *después* de la inversión publicitaria en la cadena causal. Incluirlas robaría protagonismo a los canales de marketing y haría creer que el tráfico por sí solo vende. Se usan únicamente para exploración.

2.3 Flujo del ETL

1. **Carga** de los siete CSV.
2. **Normalización de fechas** al lunes ISO.
3. **Agregación semanal nacional** para cada tabla.
4. **Pivote de la inversión** por `canal_medio` → 8 columnas `inv_*`.
5. **Merge LEFT desde ventas**: la tabla de ventas actúa como esqueleto; las demás se unen preservando todas las semanas con actividad comercial.
6. **Filtrado temporal** al rango *2020-01-06* → *2024-12-14*, desde la primera semana con inversión registrada.

2.4 Validación visual

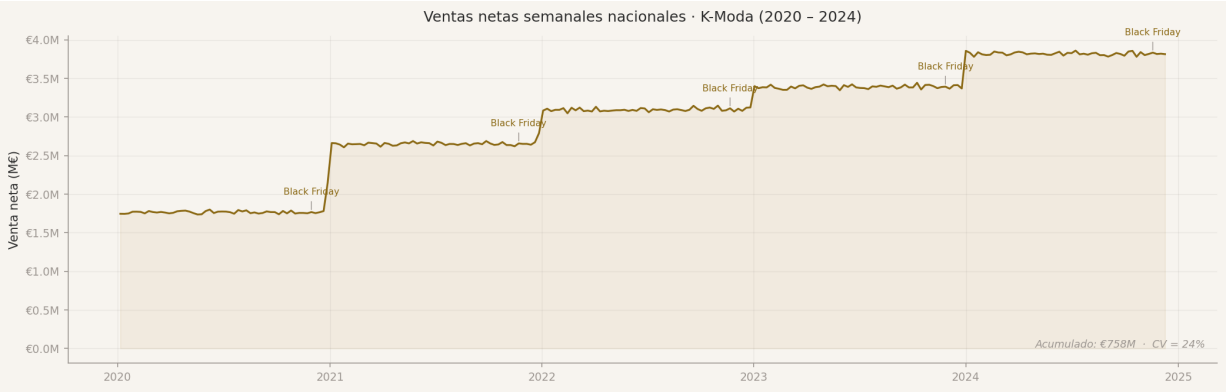

Figura 1: Ventas netas semanales 2020–2024. El target del modelo. Se observan claramente los picos de Black Friday y los escalones anuales que reflejan el crecimiento estructural del negocio.

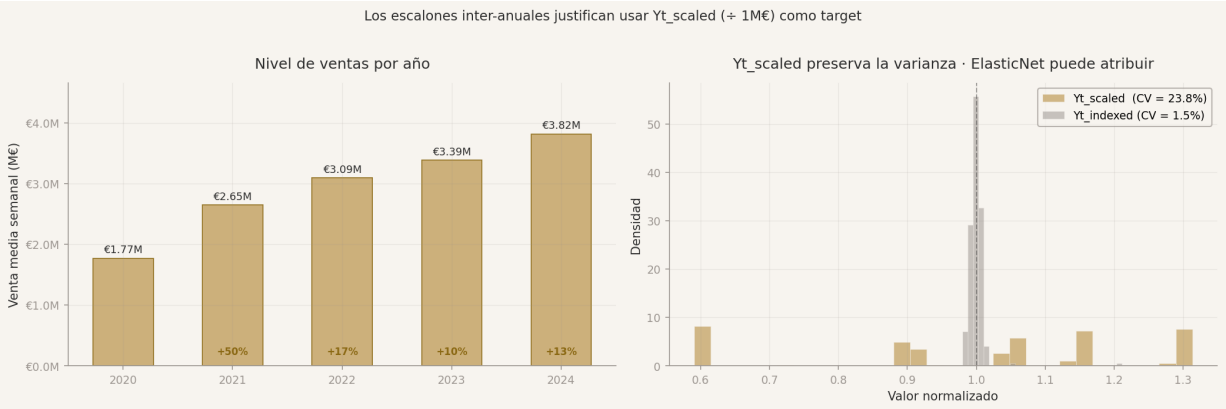

Figura 2: Escalones anuales del target. El nivel medio anual sube de forma discreta cada enero ($+30$–$50\,\%$ entre 2020 y 2021). Esta propiedad motiva las decisiones posteriores de target y de *split* train/test.

2.5 Resultado

La salida del ETL es un único fichero (`etl.csv`) con 258 filas semanales y las columnas necesarias para el resto del pipeline: `semana_inicio`, `venta_neta_total_eur` (target), ocho columnas `inv_*` (canales de inversión) y las variables de calendario y clima que actuarán como controles.

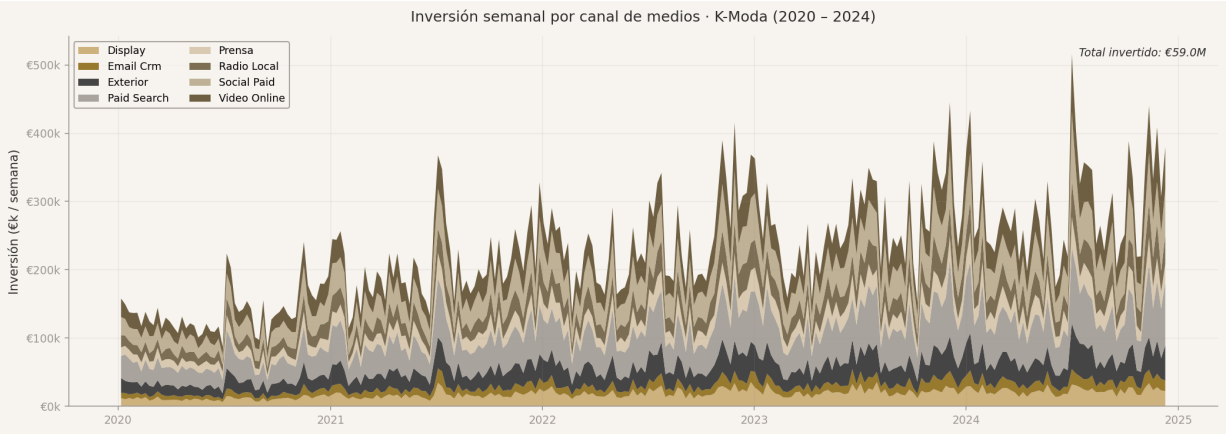

Figura 3: Inversión semanal apilada por canal. Muestra qué canales absorben más presupuesto y si hay estacionalidad o discontinuidades en el gasto.

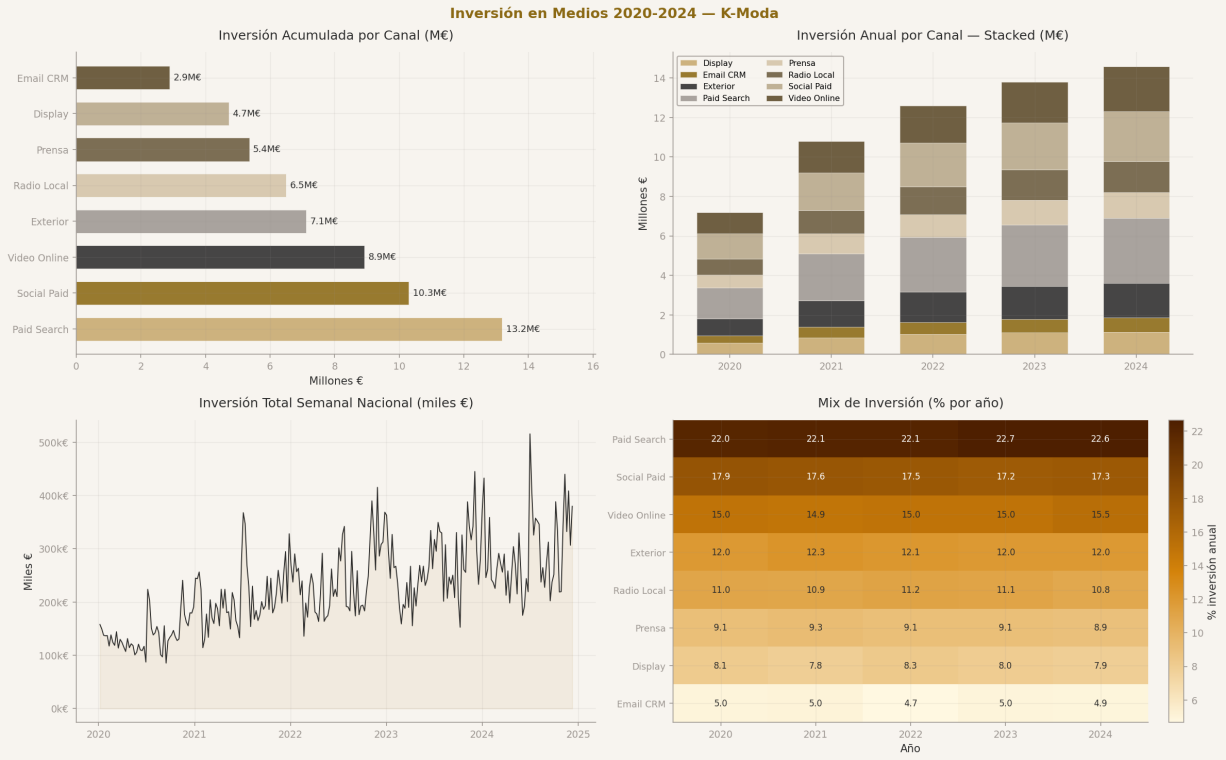

Figura 4: Overview completo de la inversión en medios: distribución por canal, evolución, composición. Vista 360º del presupuesto antes de agrupar.

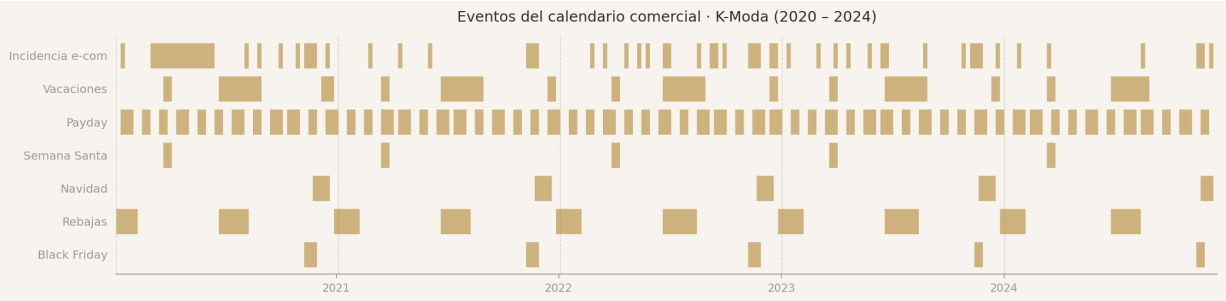

Figura 5: Calendario comercial. Presencia semanal de los siete eventos nacionales (*Black Friday*, rebajas, Navidad, etc.). Son covariables clave porque coinciden con los picos de venta y el modelo debe separarlos del efecto del marketing.

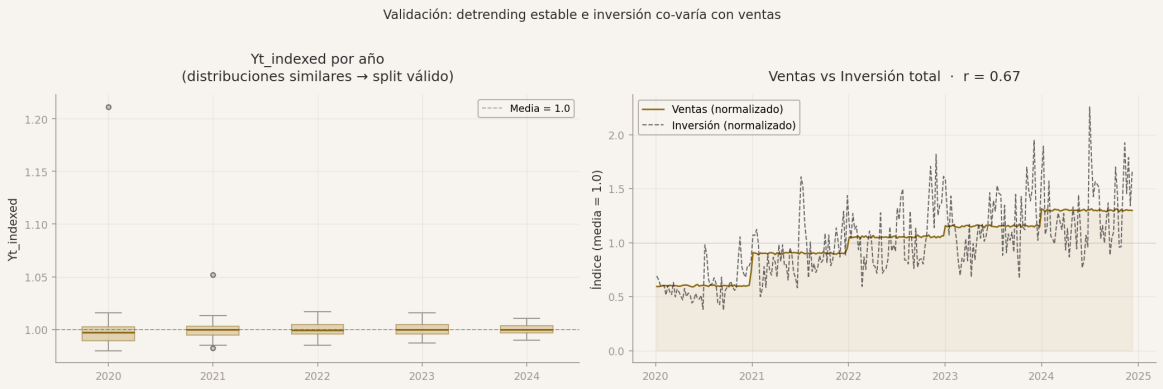

Figura 6: Validación del target. Distribuciones por año e inversión semanal total, utilizadas como sanity check antes de pasar a la fase de modelado.

3 | Data Understanding · Explorando los datos

KEY TAKEAWAY

Antes de modelar, hay que mirar. Esta fase busca respuesta a tres preguntas: **(i)** ¿las ventas son estables o tienen estacionalidad marcada?, **(ii)** ¿hay correlaciones entre los canales que puedan confundir al modelo?, y **(iii)** ¿los eventos comerciales dejan huella medible?

3.1 Distribución del target y estacionalidad

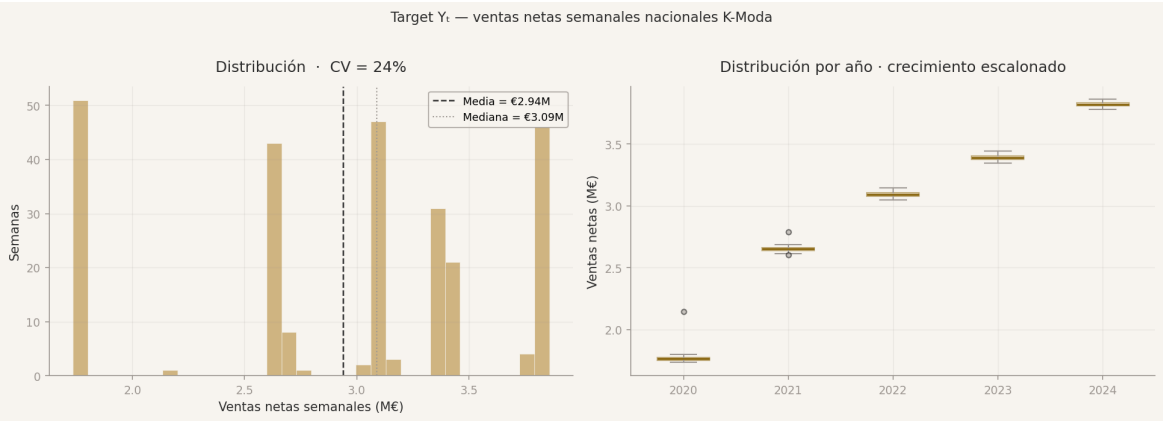

Figura 7: Distribución de ventas semanales. La asimetría a la derecha (cola larga) refleja los picos puntuales de campañas fuertes; el grueso de las semanas se concentra alrededor de la mediana.

3.2 Presupuesto y mix de inversión

3.3 Correlaciones y multicolinealidad

3.4 Eventos comerciales

3.5 Autocorrelación del target

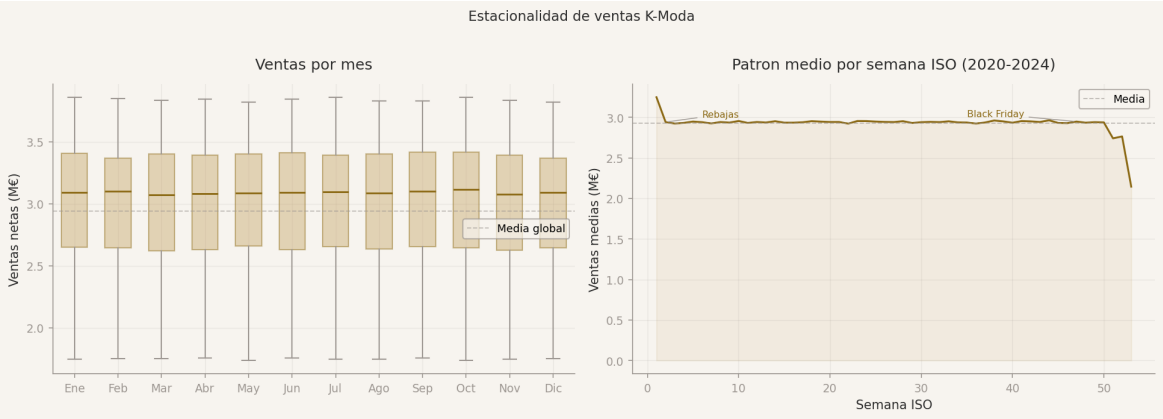

Figura 8: Estacionalidad anual. Las ventas repiten un patrón anual reconocible: valles a comienzos de año, crecimiento en primavera, pico en noviembre (*Black Friday*) y otro pico en rebajas de enero.

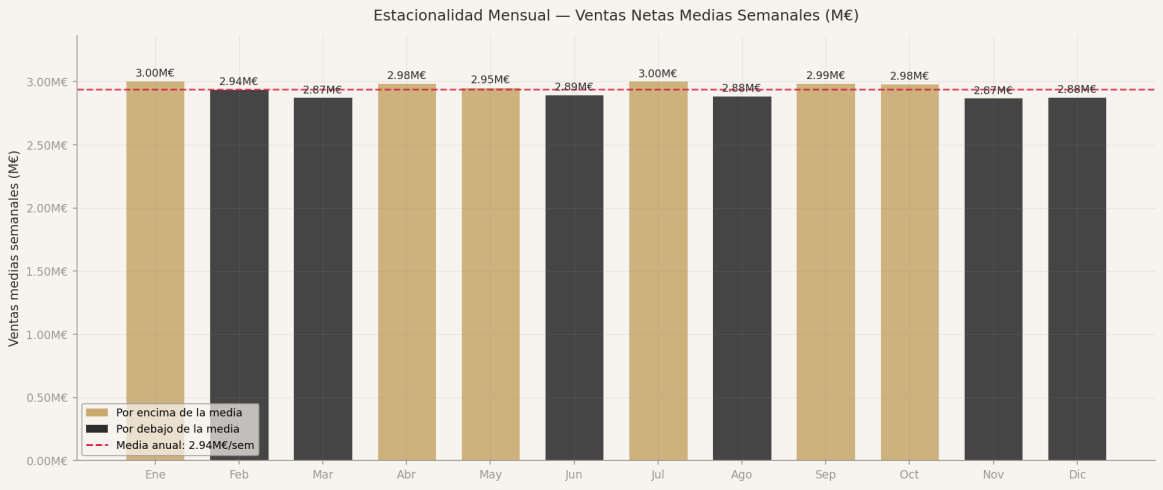

Figura 9: Vista mensual comparada por año. Permite confirmar que la estacionalidad se mantiene estable en el tiempo — no es un artefacto de un único año.

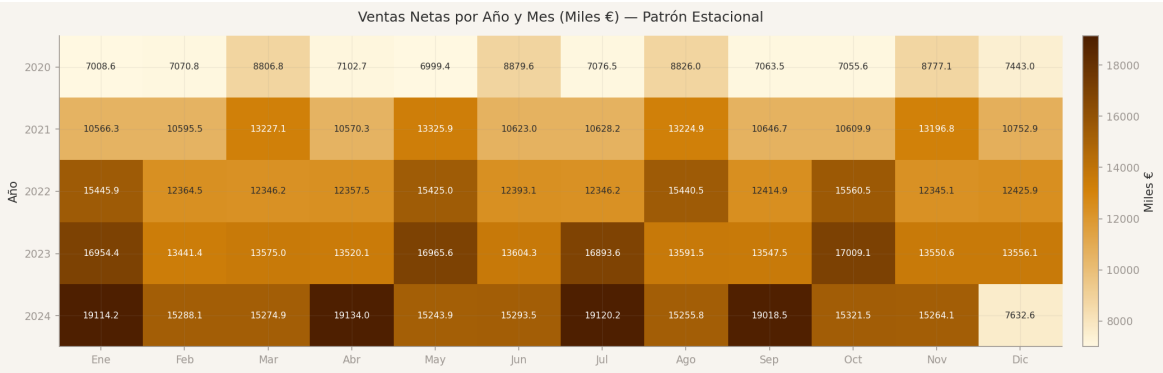

Figura 10: Heatmap año × mes. Verde claro = semanas flojas, dorado intenso = picos. La diagonal de crecimiento y la franja vertical de noviembre son las dos señales más claras.

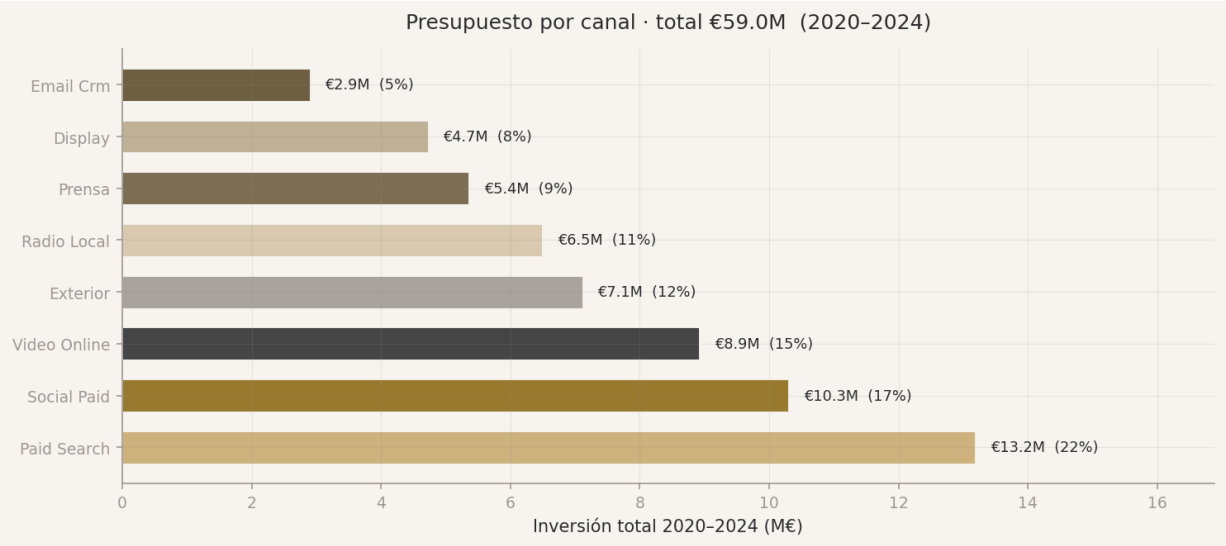

Figura 11: Presupuesto publicitario a lo largo del tiempo. Cómo ha evolucionado el gasto total y su composición entre canales.

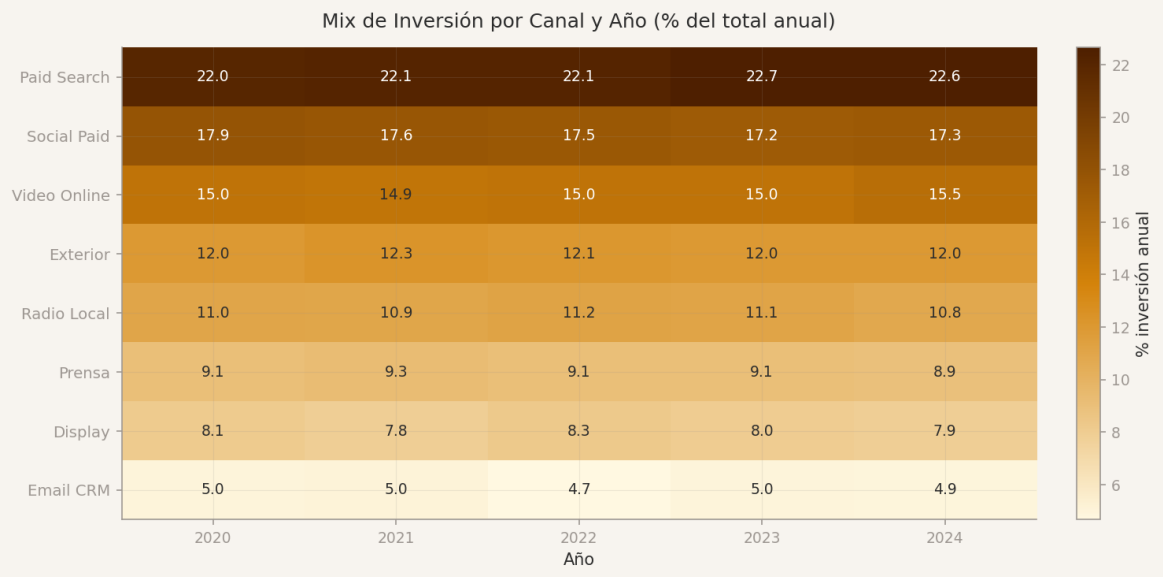

Figura 12: Mix porcentual de inversión. Qué peso relativo tiene cada canal en la cartera total. Este reparto es el *baseline* contra el que se medirán las reasignaciones propuestas.

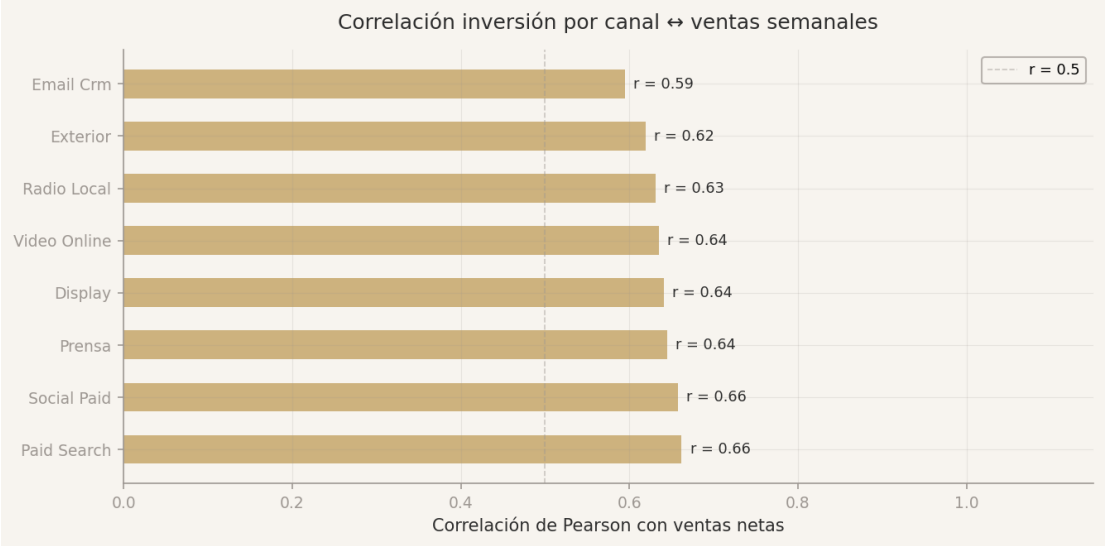

Figura 13: Matriz de correlación entre canales de inversión. Los canales están fuertemente correlacionados entre sí (ρ Spearman $\in [0{,}83, 0{,}96]$). Esto adelanta un problema de multicolinealidad que condicionará la decisión de agrupar canales en la fase de *data preparation*.

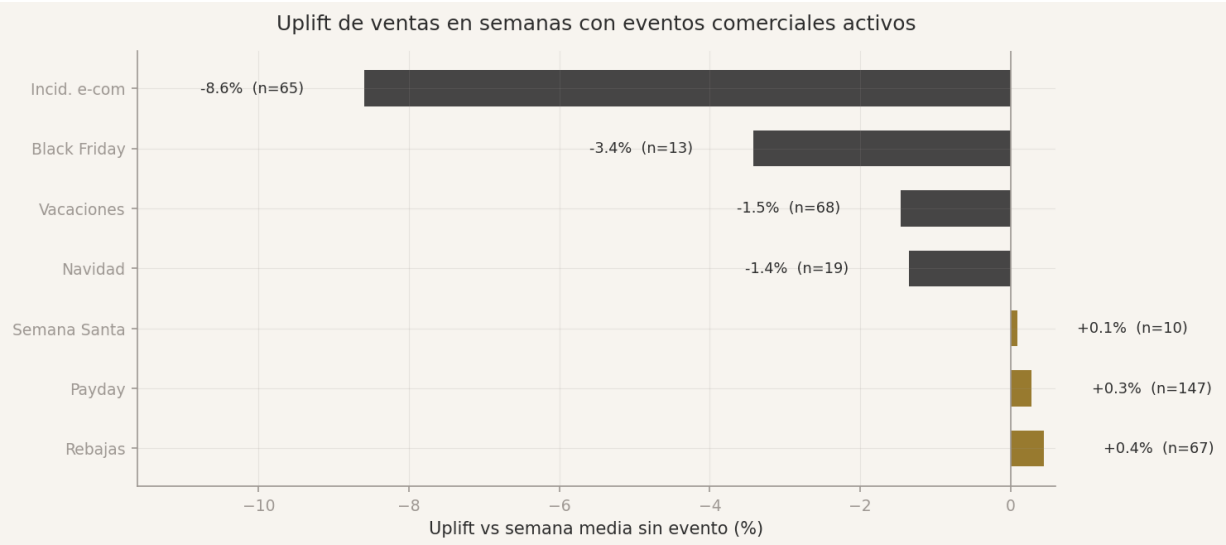

Figura 14: Uplift por tipo de evento. Mediana de ventas en semanas con y sin cada evento. Black Friday y rebajas destacan claramente; Navidad tiene efecto menor porque la preparación se adelanta semanas antes.

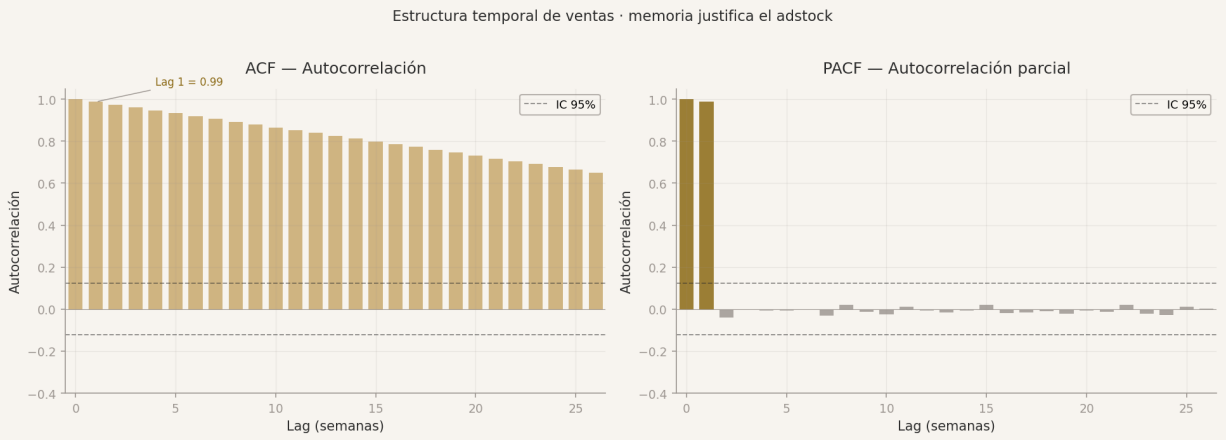

Figura 15: ACF y PACF del target. Hay autocorrelación significativa a lag 1 y memoria a largo plazo (componente de tendencia). Ambos elementos se tratan en el preprocesado: la tendencia con las variables de calendario, y la autocorrelación residual con el *block bootstrap* para estimar la incertidumbre de los coeficientes.

3.6 Conclusiones del análisis exploratorio

KEY TAKEAWAY

1. Las ventas tienen una **estacionalidad anual reconocible** y un crecimiento estructural año-a-año.
2. Los canales de inversión están **muy correlacionados entre sí** — modelar cada canal por separado dará coeficientes inestables.
3. Los **eventos comerciales** (Black Friday, rebajas) tienen uplift claro y medible, por lo que deben entrar como controles en el modelo.
4. El **tráfico web/tienda** correlaciona con ventas, pero es un mediador: no entra al modelo.

4 | Data Preparation · Del euro al coeficiente

KEY TAKEAWAY

Tres transformaciones convierten el gasto bruto en una señal que el modelo puede aprender: **(1)** agrupación de los 8 canales en **4 grupos** según su mecánica de respuesta, **(2)** *adstock* con α diferenciado por grupo, y **(3)** saturación logarítmica (retornos decrecientes). El resto del pipeline se apoya íntegramente en este bloque.

4.1 De 8 canales a 4 grupos

La fase exploratoria ya avisó: los ocho canales de inversión están correlacionados entre sí con ρ de Spearman entre 0.83 y 0.96. Traducido: cuando invertimos en uno, solemos invertir en varios a la vez. Para una regresión con restricción `positive=True` esto es letal — los canales se "canibalizan" y el modelo termina anulando varios de ellos arbitrariamente.

DECISIÓN TÉCNICA

Solución: agrupar los ocho canales en cuatro grupos con mecánica de respuesta distinta. Cada grupo suma dos canales:

Grupo	Canales que lo forman	α	Lag
Performance	`paid_search` + `social_paid`	0.20	0
Branding Digital	`display` + `video_online`	0.50	1
Offline Medios	`radio_local` + `prensa`	0.60	1
Propios y Exterior	`email_crm` + `exterior`	0.70	0

Cuatro grupos con α crecientes (memoria desde 1 semana hasta varios meses) $\rightarrow$ coeficientes estables, intervalos de confianza manejables, y la granularidad que necesita el directivo para tomar decisiones.

4.2 Adstock · La memoria publicitaria

Un anuncio no deja de surtir efecto al día siguiente. El consumidor lo recuerda durante semanas. Se modela así:

$$A_t = x_{t-\text{lag}} + \alpha \cdot A_{t-1}$$

donde x_t es la inversión en la semana t, α el *decaimiento* semanal, lag el retardo hasta que empieza el efecto, y A_t el "stock" publicitario acumulado.

- **Performance** ($\alpha = 0{,}20$): respuesta casi inmediata, memoria corta (paid search y social responden el mismo día).
- **Branding Digital** ($\alpha = 0{,}50$, lag 1): efecto retardado de una semana y memoria media.
- **Offline Medios** ($\alpha = 0{,}60$, lag 1): radio y prensa penetran con retardo y dejan recuerdo más largo.
- **Propios y Exterior** ($\alpha = 0{,}70$): email CRM e imagen exterior construyen memoria a largo plazo ($\sim$2 meses de vida media).

DECISIÓN TÉCNICA

Los α por grupo se fijan con priors de literatura, no se calibran. Razón: con correlaciones tan altas entre grupos, la calibración automática converge siempre a la esquina del grid ($\alpha \approx 0{,}90$, lag $= 4$) — una solución matemáticamente óptima pero sin sentido de negocio. Usar priors de literatura mantiene el modelo interpretable.

4.3 Saturación · Retornos decrecientes

Invertir el doble no vende el doble. A partir de cierto punto, cada euro adicional rinde menos. Se modela con un logaritmo:

$$\text{logadstock}_t = \log\left(1 + \frac{A_t}{k}\right)$$

donde k es la escala característica de cada grupo (percentil 60 de sus valores positivos). En nuestro caso $k \in [112\text{k}, 139\text{k}]$ según el grupo. Esta transformación:

- **suaviza los picos** de inversión (un mes de TV/exterior brutal no tiene un efecto 10$\times$),
- **estandariza las escalas** entre grupos que operan en órdenes de magnitud similares pero no idénticos,
- **introduce la saturación** que más tarde se explotará en el simulador del dashboard.

4.4 Visualización de la transformación

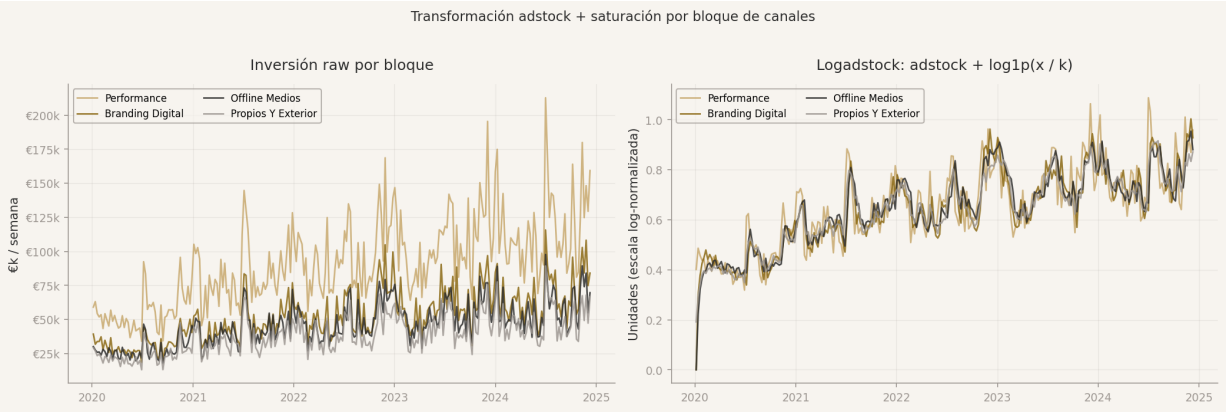

Figura 16: Inversión bruta vs. logadstock por grupo. Arriba, la inversión semanal bruta de cada grupo: picos puntuales y ceros. Abajo, tras aplicar *adstock* + saturación: señales suaves, persistentes en el tiempo, que reflejan la memoria acumulada de la marca. Estas son las cuatro variables de marketing que verá el modelo.

4.5 Feature set final

Tras la preparación, el modelo recibe **19 variables**:

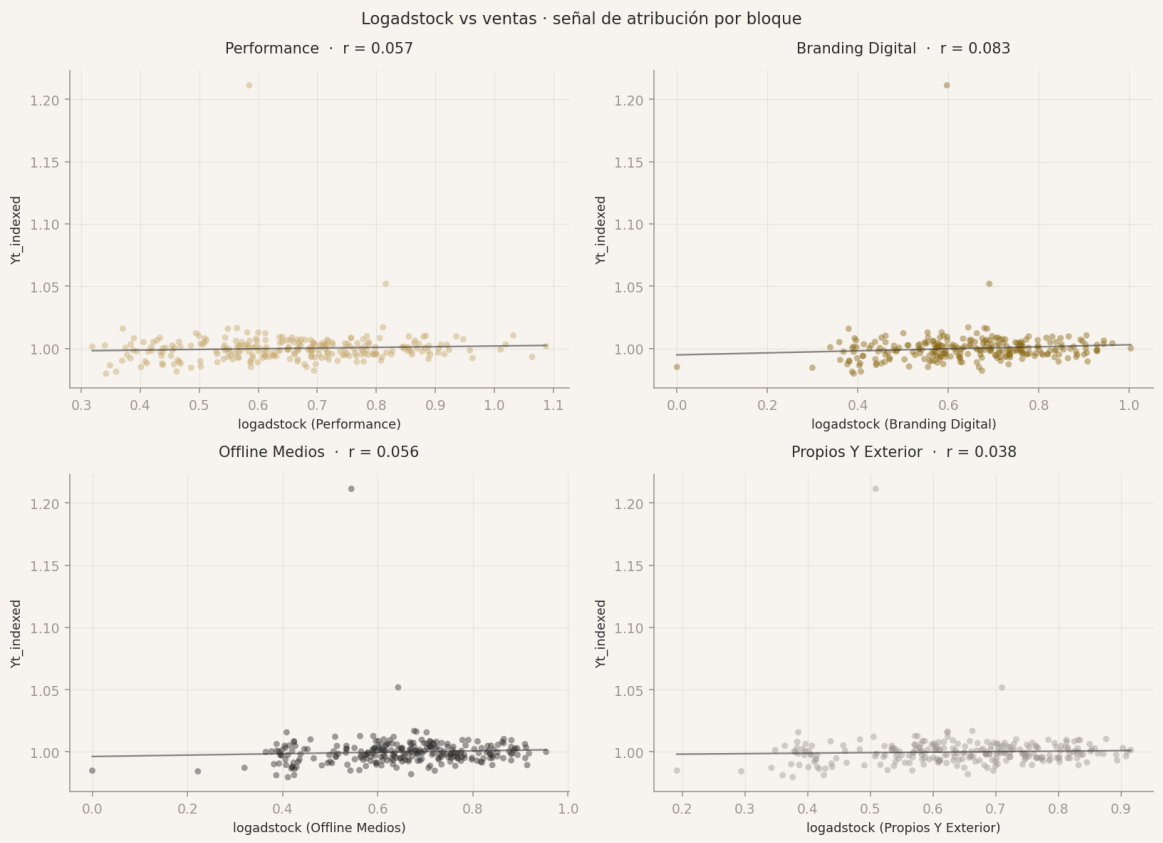

Figura 17: Señal logadstock vs. ventas. Una correlación positiva tras la transformación confirma que la señal de cada grupo co-varía con las ventas en la dirección esperada. Requisito mínimo antes de pasar al modelo: sin esto, no hay nada que aprender.

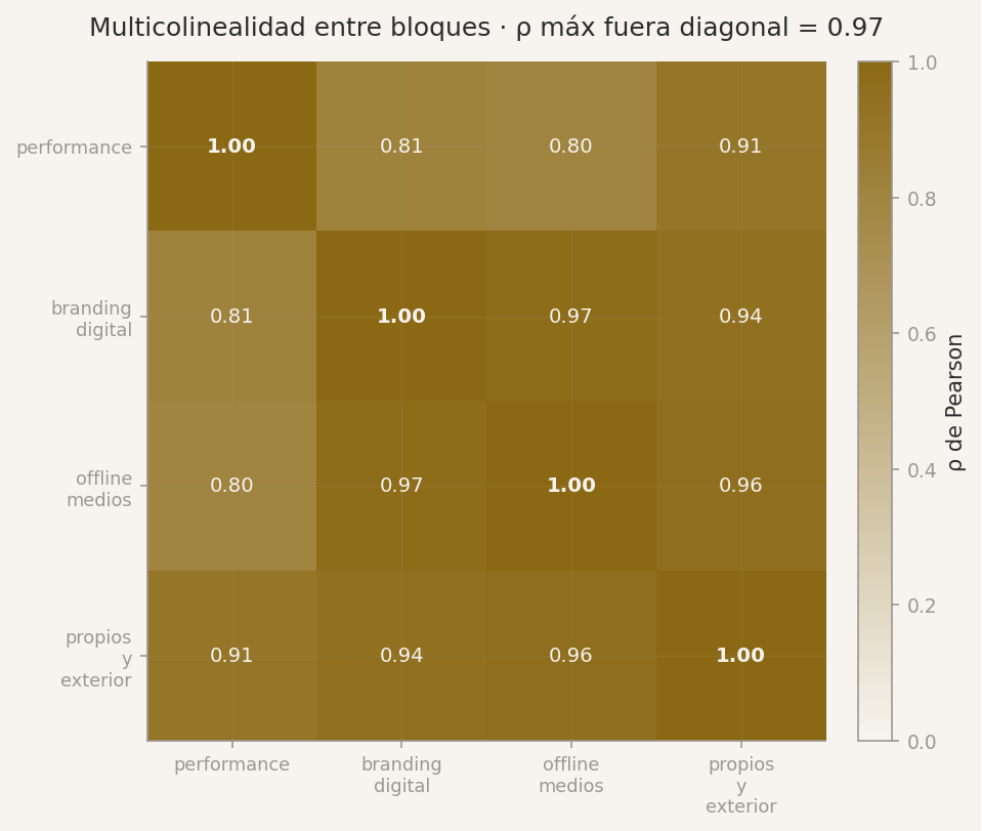

Figura 18: Multicolinealidad entre los 4 grupos transformados. Tras la agrupación y el adstock con α diferenciado, los cuatro grupos quedan en correlación *manejable*, que es lo que permite a ElasticNet separar la contribución de cada uno.

Tipo	Variables	N.º
Marketing	`logadstock_performance`, `_branding_digital`, `_offline_medios`, `_propios_y_exterior`	4
Estacionalidad	Fourier $\sin / \cos$ orden 1 y 2 (anual)	4
Calendario	*payday, rebajas, Black Friday, Navidad, Semana Santa, vacaciones escolares, incidencia ecommerce*	7
Festivos	`festivo_local_intensidad`	1
Controles	`temperatura_media_c`, `lluvia_indice`, `turismo_indice`	3
	Total (+ intercepto)	**19**

El conjunto se escala con un `StandardScaler` antes de entrar al modelo para que la penalización ElasticNet trate a todas las variables en igualdad de condiciones.

5 | Modeling · Ajuste y validación

KEY TAKEAWAY

Se entrena una regresión **ElasticNet con coeficientes no negativos** sobre las 19 variables del bloque anterior. Hiperparámetros elegidos por *cross-validation*: $\alpha = 0{,}117$, ℓ_1-ratio $= 0{,}30$. El modelo se valida con un *hold-out* estratificado por año y se estiman intervalos de confianza por *bootstrap* en bloques de 4 semanas (500 iteraciones).

5.1 Por qué ElasticNet y por qué `positive=True`

DECISIÓN TÉCNICA

ElasticNet combina regularización L1 (como *Lasso*: empuja a cero coeficientes poco informativos) y L2 (como *Ridge*: estabiliza ante multicolinealidad). Para un problema con 19 variables, algunas correlacionadas, es el compromiso natural.

DECISIÓN TÉCNICA

`positive=True` es la restricción económica central del MMM: *ningún canal puede tener contribución negativa a las ventas*. Invertir en publicidad no resta ventas. Sin esta restricción, los coeficientes pueden volverse negativos por puro artefacto estadístico (multicolinealidad residual), lo que hace imposible defender el modelo ante un directivo.

5.2 Split train/test · Estratificado por año

DECISIÓN TÉCNICA

El split es **estratificado por año** (20 % test de cada año), no puramente temporal. Motivación:

- El target crece en escalones anuales claros (+30–50 % entre 2020 y 2021).
- Dentro de cada año, el coeficiente de variación es muy bajo ($\sim$0.5–3 %).
- Un *hold-out* puro de 2024 tendría una desviación tan pequeña que el R^2 saldría degenerado.
- Un split estratificado preserva la varianza multianual y es válido para **atribución** (que es el objetivo del MMM), aunque no lo sea para *forecasting* puro.

El *block bootstrap* posterior se encarga de preservar la autocorrelación para la incertidumbre de los β.

5.3 Ajuste final

5.4 Coeficientes e incertidumbre

Grupo	β (M€/unidad)	IC 95 %
Performance	0.103	[0.066, 0.196]
Branding Digital	0.093	[0.027, 0.188]
Offline Medios	0.190	[0.087, 0.243]
Propios y Exterior	0.238	[0.143, 0.286]

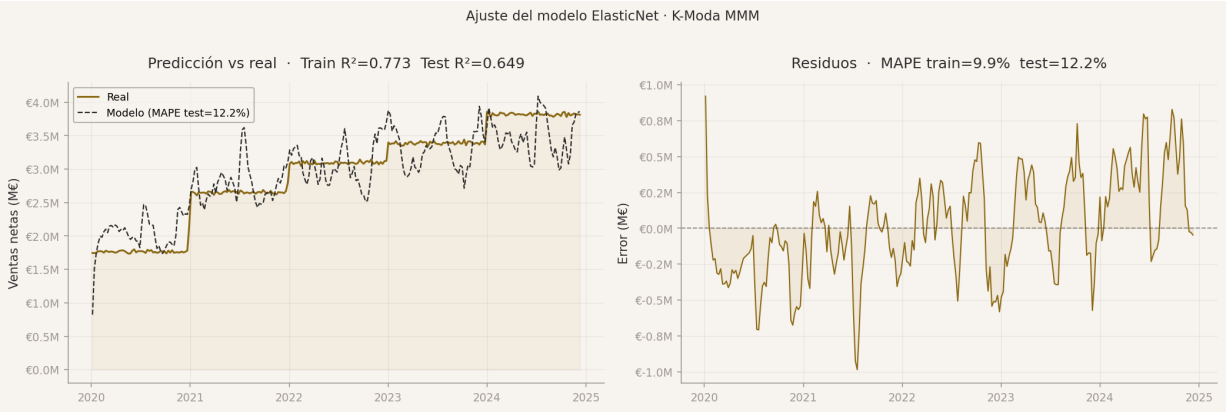

Figura 19: Ajuste del modelo. La línea modelada (punteada) sigue de cerca las ventas reales en todo el período, incluyendo los picos de Black Friday y rebajas. Los residuos no muestran patrón sistemático.

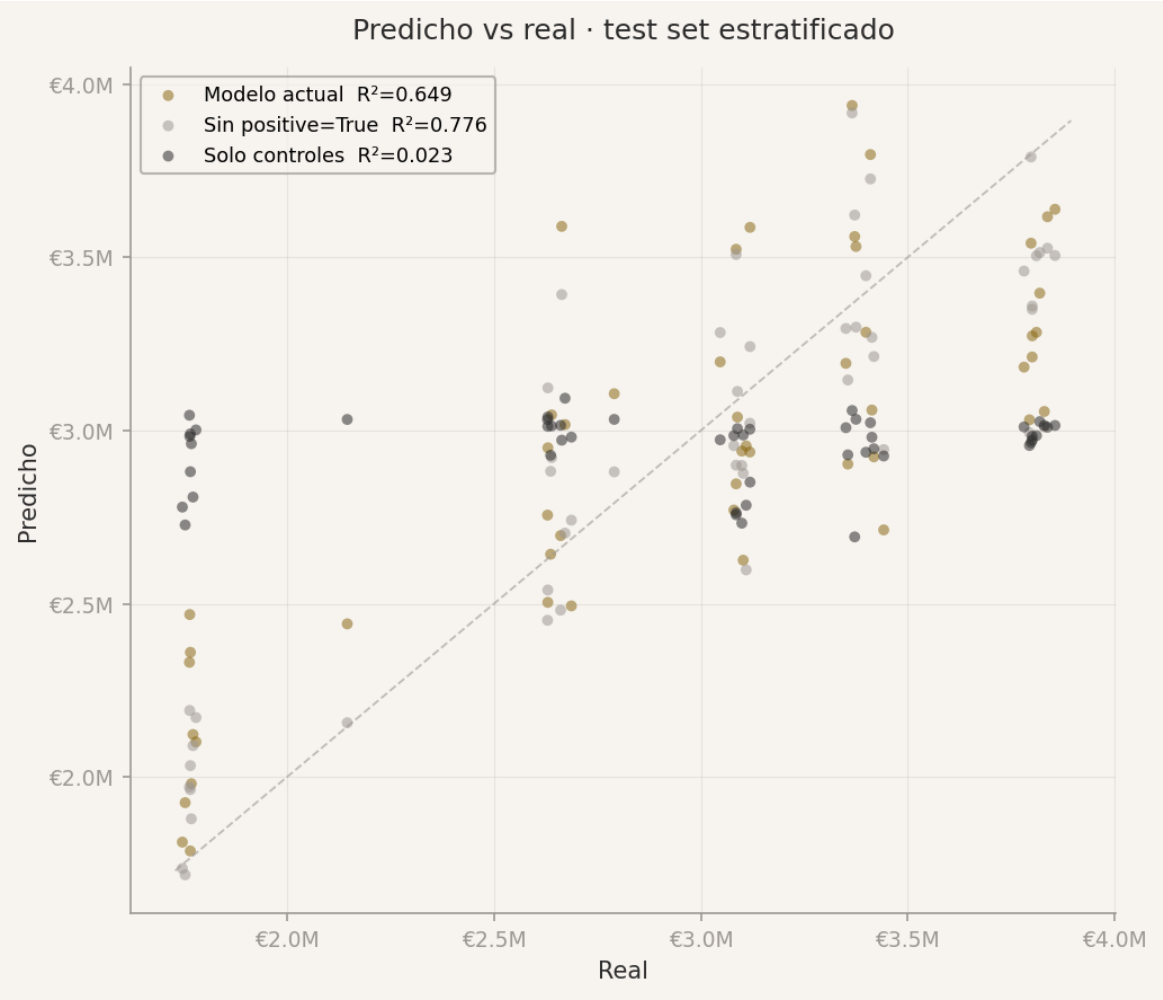

Figura 20: Real vs. predicción en test. Los puntos se alinean con la diagonal sin sesgo sistemático. La ablación (*sin positive=True* y *sin medios*) se incluye como control: permite comprobar que la restricción económica no penaliza el ajuste, y que los grupos aportan señal real.

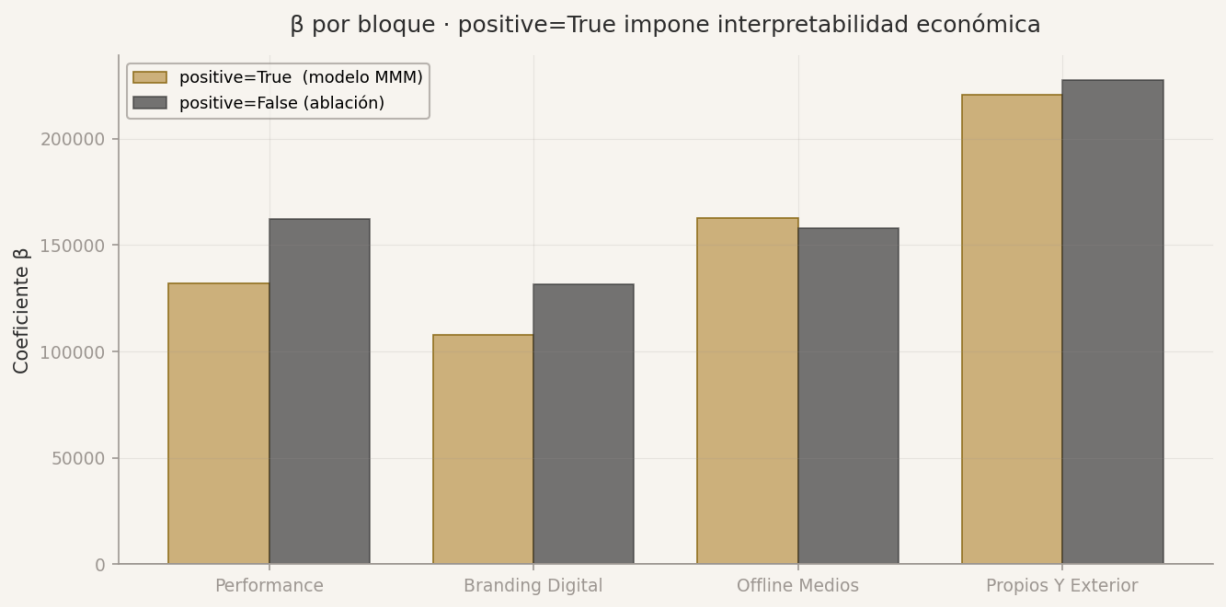

Figura 21: Coeficientes β del modelo. Cada barra es el efecto marginal de una variable (escala transformada). Los cuatro grupos de marketing aparecen positivos gracias a `positive=True`. El modelo también retiene señal de `fourier_sin1` (estacionalidad anual), `semana_santa_flag`, `festivo_local_intensidad` y `temperatura_media_c`; el resto de flags de calendario la regularización los empuja a 0 porque la Fourier + eventos de marketing ya capturan la estacionalidad.

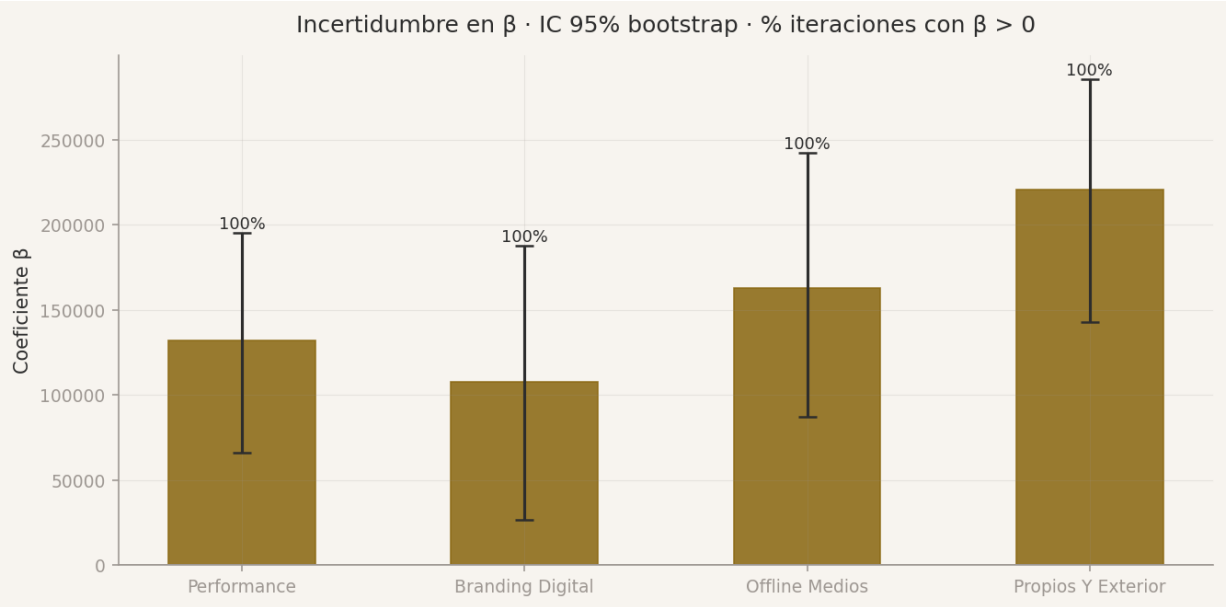

Figura 22: Intervalos de confianza vía *block bootstrap*. 500 iteraciones con bloques contiguos de 4 semanas (para preservar autocorrelación). Los cuatro grupos de marketing tienen IC 95 % que **no cruzan cero** → contribución robusta:

5.5 Test placebo

DECISIÓN TÉCNICA

¿Capturamos señal real o ruido? Sustituimos las inversiones por ruido con la misma media, desviación y autocorrelación, y reentrenamos.
Resultado: $R^2_{\text{placebo}} = 0{,}114$ vs. $R^2_{\text{test}} = 0{,}649$ del modelo real $\rightarrow \Delta R^2 = +0{,}535$. El modelo no sobrevive sin los datos reales de inversión — la señal de medios es necesaria.

5.6 Descomposición de ventas

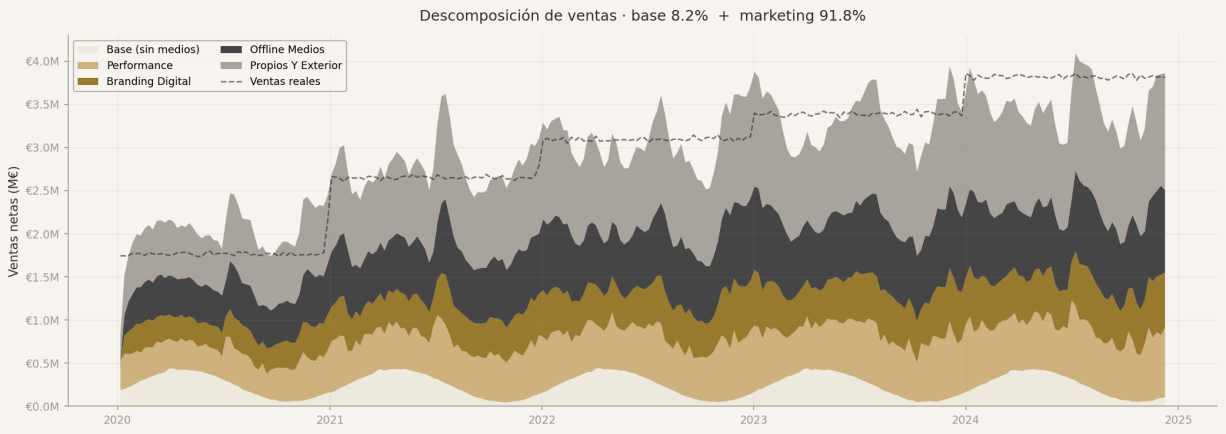

Figura 23: Descomposición base vs. marketing. Cada semana se descompone en la fracción atribuida a la base orgánica (SEO, marca, recurrencia) y la fracción atribuida al marketing (suma de los cuatro grupos). La capa dorada es el *value* que el equipo de marketing puede reclamar; la capa gris es lo que la empresa vendería sin publicitar según el modelo.

5.7 Métricas finales

Métrica	Valor	Interpretación
R^2 train	$0{,}773$	Buen ajuste interno.
R^2 test	$0{,}649$	Generaliza fuera de muestra.
MAPE train	$9{,}9\,\%$	
MAPE test	$12{,}2\,\%$	En rango válido para MMM (8–20 %).
R^2 placebo	$0{,}114$	Modelo alternativo con medios = ruido.
ΔR^2 placebo	$+0{,}535$	Gap muy grande $\rightarrow$ señal real confirmada.

KEY TAKEAWAY

El modelo es **sencillo por diseño**: 19 variables, restricciones económicas, validación rigurosa. El R^2 test de 0.65 y el MAPE de 12.2 % son sanos para un MMM — la literatura sitúa MAPE por debajo del 8 % como señal de *overfit* y por encima del 20 % como señal no capturada. Estamos en el medio, justo donde se quiere estar.

6 | Evaluation · Atribución, escenarios y sensibilidad

KEY TAKEAWAY

Una vez validado el modelo, se usa para responder las preguntas de negocio: **(i)** qué % de las ventas atribuimos al marketing, **(ii)** cuánto ganaríamos reasignando presupuesto desde *Performance* hacia *Propios y Exterior*, y **(iii)** qué tan sensible es el resultado a pequeños errores en los β.

6.1 Calidad del ajuste recap

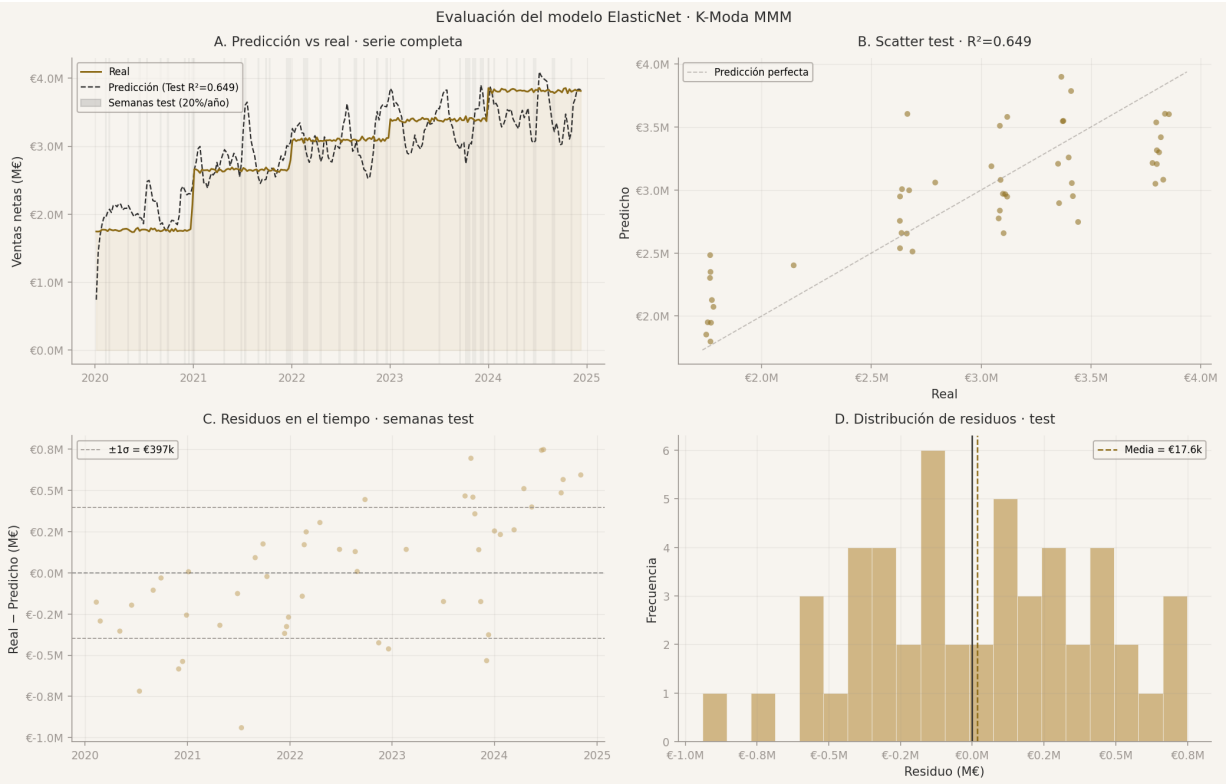

Figura 24: Ajuste del modelo revisitado. Línea real vs. predicción, con separación visual entre train y test.

6.2 Atribución · ¿Cuánto viene del marketing?

Sobre las 258 semanas analizadas (2020–2024) y 758.1 M€ de ventas acumuladas, la descomposición del modelo arroja:

Grupo	Inversión (M€)	Contribución (M€)	ROI
Performance	23.5	141.8	**6.0**×
Branding Digital	13.6	115.4	8.5×
Offline Medios	11.8	181.0	15.3×
Propios y Exterior	**10.0**	**256.7**	**25.7**×
Total marketing	**58.9**	**695.0**	**11.8**× (ponderado)

La suma de contribuciones equivale al **91.8 % de las ventas totales** del periodo.

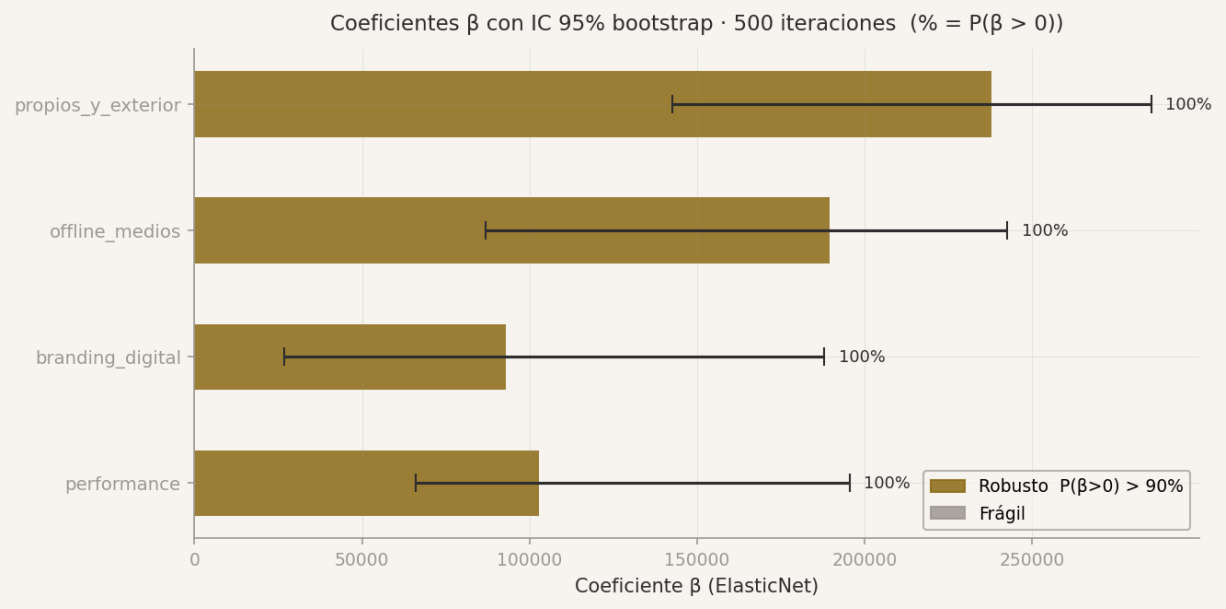

Figura 25: Coeficientes finales con intervalos de confianza. Los cuatro grupos de marketing son positivos y sus IC 95 % no cruzan cero → contribución robusta.

DECISIÓN TÉCNICA

Nota honesta sobre el 91.8 %. Este número es elevado comparado con benchmarks de MMM en retail físico (típicamente 20–40 % atribuido a medios). Hay que leerlo así: es el resultado de un **contrafactual** — "si K-Moda no hubiera invertido nada en publicidad desde 2020, el modelo predice 63 M€ de ventas acumuladas, en lugar de los 758 M€ observados". Este contrafactual no contempla la **inercia de marca** que K-Moda ya tiene en 2020: parte de lo que el modelo atribuye a medios es, en realidad, memoria de campañas anteriores a 2020 que no están en los datos. El porcentaje es válido *relativamente* (compara grupos entre sí) pero debe presentarse con este matiz ante el comité.

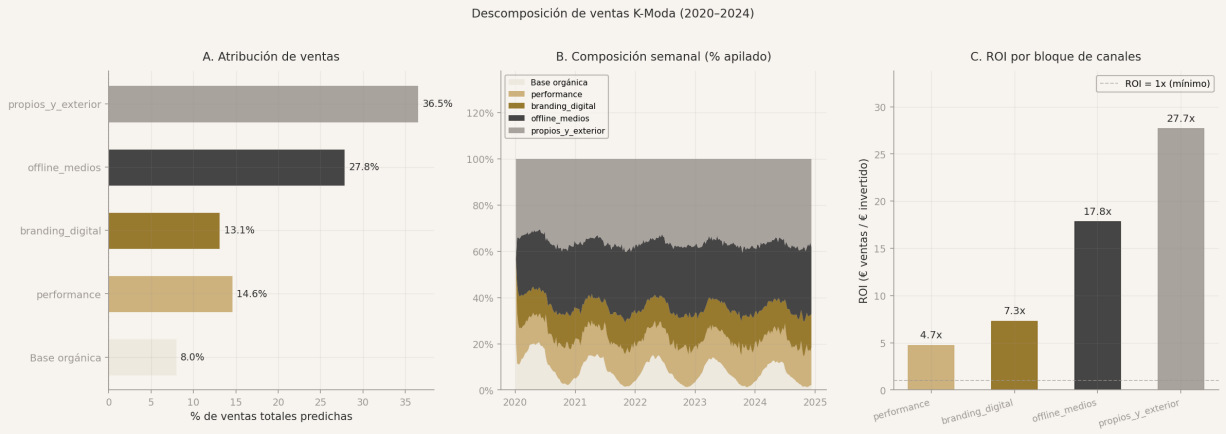

Figura 26: Descomposición final. Capa dorada = marketing atribuido; capa gris = base orgánica. La descomposición se lee semana a semana en el dashboard.

DECISIÓN TÉCNICA

Metodología de atribución (estándar MMM):

$$\text{Ventas predichas} = \text{Base orgánica} + \sum_{\text{grupo}} \beta_{\text{grupo}} \cdot x_{\text{grupo,escalado}}$$

Cada grupo aporta su β multiplicado por su variable transformada (logadstock). Sumando las cuatro contribuciones se obtiene el total atribuible; la *base* es lo que quedaría con $\texttt{inversión} = 0$.

6.3 Simulación de escenarios

La función `simular(inv_nueva)` toma un vector de inversión semanal por grupo, aplica los mismos *adstocks* y saturaciones que vio el modelo, y devuelve las ventas anuales proyectadas, el *lift* vs. baseline y el ROI. Con ella se definen tres escenarios canónicos:

Escenario	Descripción	Qué mide
DO NOTHING	Mantener el reparto histórico.	Baseline.
DO SOMETHING	Transferir el 30 % del grupo con menor ROI (*Performance*) al de mayor ROI (*Propios y Exterior*).	Upside realista sin aumentar presupuesto.
DO THE MOST	Reasignar el 60 % de Performance a Propios y Exterior.	Upside ambicioso, concentrando riesgo.

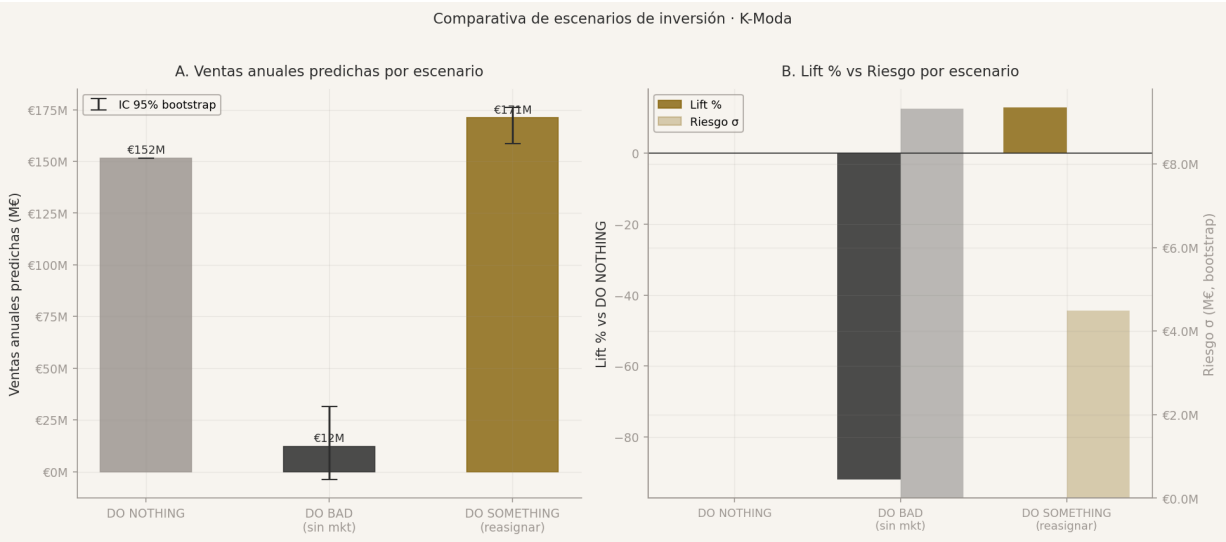

Figura 27: Comparativa de los tres escenarios. DO SOMETHING captura la mayor parte del *upside* con la menor perturbación al mix actual. DO THE MOST añade incremento marginal pero concentra el riesgo en un único grupo.

6.4 Curvas de respuesta · Rendimientos decrecientes

6.5 Presupuesto: baseline vs. propuesta

6.6 Tornado de sensibilidad

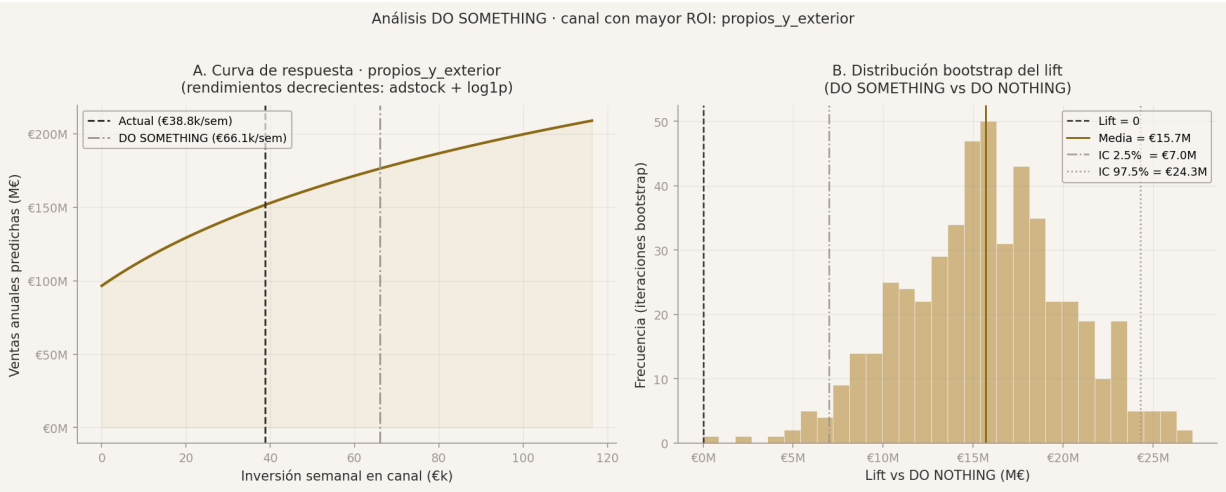

Figura 28: Curvas de respuesta por grupo. Muestran cómo reaccionan las ventas al aumentar la inversión en cada grupo, manteniendo los demás constantes. La zona continua es de crecimiento; la zona punteada es saturación (cada euro adicional rinde menos del 10 % del pico). Los puntos marcan el nivel histórico actual — clave para identificar dónde hay recorrido y dónde no.

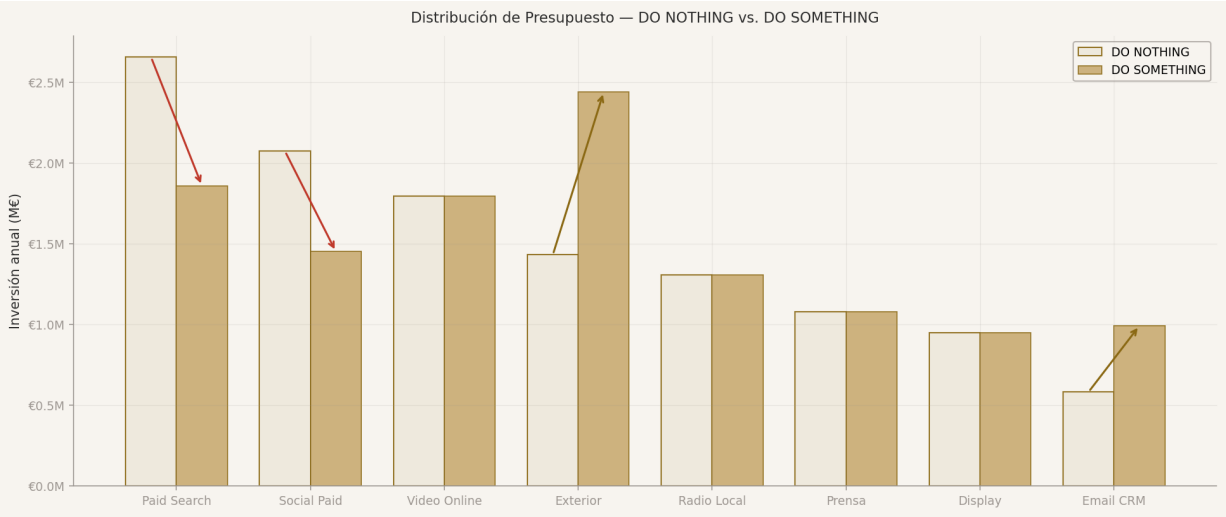

Figura 29: Distribución del presupuesto: DO NOTHING vs. DO SOMETHING. Visualización grupo a grupo de la reasignación propuesta. El 30 % que sale de Performance entra en Propios y Exterior.

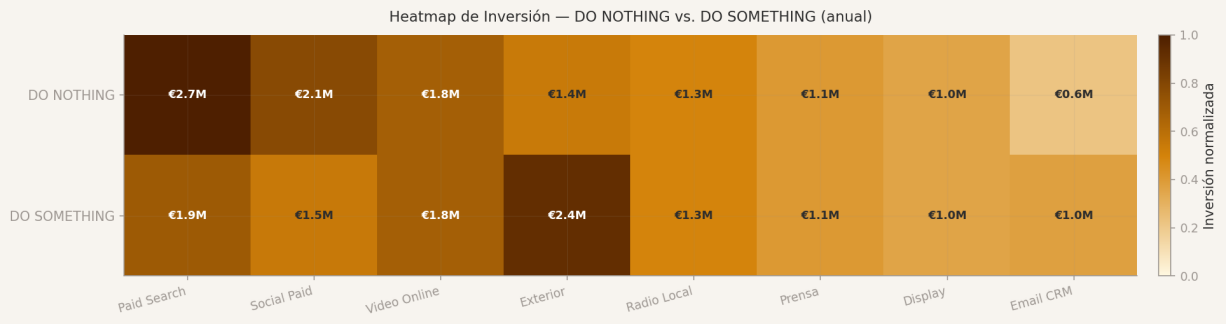

Figura 30: Heatmap de inversión normalizada. Intensidad proporcional al gasto en cada grupo bajo cada escenario. Una forma compacta de ver el *antes* y *después* del reparto.

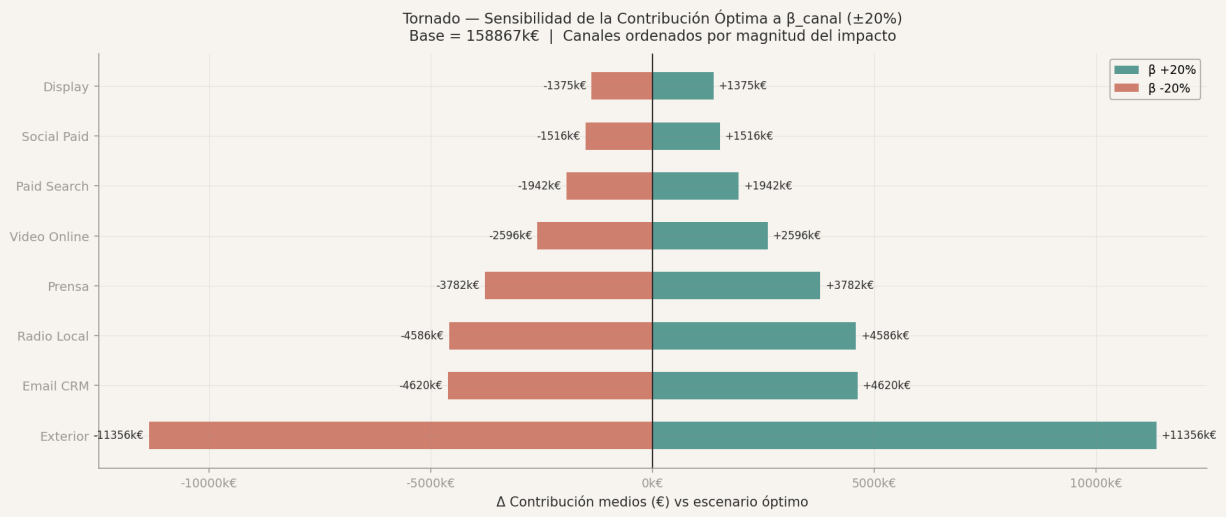

Figura 31: Sensibilidad a $\pm 20\,\%$ en los β. Muestra cuánto cambiaría la contribución total del marketing si el coeficiente de cada grupo fuera un 20 % mayor o menor. Los grupos con barras largas (*Propios y Exterior* y *Offline Medios*) son los que más influyen en el resultado — son los que más cuidado exigen al reasignar presupuesto.

6.7 Lectura para comité

KEY TAKEAWAY

1. **Orden de eficiencia claro y robusto:** Propios y Exterior (25.7×) > Offline Medios (15.3×) > Branding Digital (8.5×) > Performance (6.0×).
2. **Performance es el grupo saturado**: recibe 40 % del presupuesto publicitario pero genera el ROI más bajo de los cuatro.
3. **Propios y Exterior está infrainvertido**: genera el mayor retorno por euro y recibe el menor presupuesto absoluto (10 M€ de 58.9 M€ totales).
4. **Reasignar antes de aumentar**: el lift de DO SOMETHING se obtiene **sin aumentar el gasto total**.
5. **Riesgo acotado**: los IC 95 % no cruzan cero y el tornado muestra que errores del $\pm 20\,\%$ en β no invierten la ordenación.

7 | Dashboard · El modelo en manos del comité

KEY TAKEAWAY

El modelo se expone a través de un **panel interactivo** (Streamlit) estructurado en cuatro pestañas, con cuatro visualizaciones animadas diseñadas para que un directivo entienda el MMM sin necesidad de ver código. El objetivo no es *wow-factor*: es que la persona que decide el presupuesto pueda **explorar** escenarios por sí misma.

7.1 Filosofía de diseño

- **Narrativa, no dashboard frío.** Cada pestaña cuenta una parte de la historia. No es una colección de gráficos: es un recorrido.
- **Paleta sobria.** Fondo oscuro, acento dorado, tipografía *Playfair Display* (titulares) + *Inter* (texto) — lenguaje visual de lujo acorde con K-Moda.
- **Interactividad con propósito.** Cada animación responde a una pregunta concreta de negocio, no decora.
- **Feedback claro al usuario.** Los botones *play* están resaltados con badge pulsante dorado para que no pasen inadvertidos entre tanta información.

7.2 Estructura en cuatro pestañas

Pestaña	Qué responde
1 · Visión General	¿Cómo han evolucionado las ventas? ¿Qué fracción viene del marketing? Incluye el *hero* con capa base + capa marketing apiladas, y la **Hélice de Ventas** en 3D.
2 · Canales y Atribución	¿Qué canal es más eficiente? ¿Qué aporta cada uno? Cascada de atribución, áreas semanales, evolución anual y tabla con IC.
3 · Laboratorio de Inversión	¿Y si movemos presupuesto? Incluye mapa 2D de 350 escenarios, curvas de retorno, **Colina de Respuesta 3D**, **Lluvia de Escenarios 3D**, tornado, escenarios predefinidos y simulador interactivo.
4 · El Modelo	¿Cuánto me fío? Real vs. predicción, residuos, coeficientes y simulador de *adstock* con **Osciloscopio** animado.

7.3 Visualizaciones animadas · El diferencial

Cuatro visualizaciones específicamente diseñadas para *contar* el modelo, no solo mostrarlo:

Hélice de Ventas 3D

Cilindro tridimensional donde la base representa el calendario anual (12 meses en círculo), la altura es el tiempo cronológico (2020→2024), y el radio se despega de la base proporcionalmente a las ventas semanales. Al pulsar *play*, la hélice se dibuja semana a semana, mostrando el crecimiento estructural (la hélice se ensancha cada año) y el ruido estacional (ondulaciones dentro de cada vuelta). *Pedagógica*: visualiza la estacionalidad y el crecimiento a la vez.

Colina de Respuesta 3D

Superficie 3D donde los ejes X e Y son la inversión semanal en los dos grupos más contributivos del modelo (*Propios y Exterior* y *Offline Medios*), y Z son las ventas anuales proyectadas. La colina se aplana donde los canales saturan. Un punto animado ejecuta *gradient ascent* desde el mix histórico hasta el óptimo, mostrando físicamente cómo el modelo *sube la colina*. *Resuelve el problema*: hace tangible el concepto de rendimientos decrecientes.

Lluvia de Escenarios 3D

Nube de 220 escenarios distintos donde X = concentración del mix (*Herfindahl*), Y = ΔVentas vs. baseline, Z = riesgo (desviación bootstrap), color = ROI marginal. Los escenarios caen ordenados por ΔVentas ascendente — los mejores aterrizan al final. *Lectura directiva*: el óptimo no es el punto más alto en Y, es el que maximiza Y con el menor Z posible; invita a pensar en la frontera riesgo-upside.

Osciloscopio de Adstock

Vista doble: arriba, impulsos de inversión en semanas concretas (campañas); abajo, la onda dorada de memoria adstock que resulta de convolver esos impulsos con el decaimiento α. Un barrido tipo CRT recorre la línea temporal mostrando cómo cada campaña deja estela y cómo campañas encadenadas construyen memoria de marca. *Pedagógica*: traduce la fórmula del *adstock* en intuición visual inmediata.

7.4 Simulador interactivo

Además de los escenarios predefinidos, el dashboard incluye un **simulador abierto** donde el usuario ajusta la inversión semanal en cada canal mediante sliders y ve en tiempo real:

- ventas anuales proyectadas,
- *lift* vs. baseline,
- ROI resultante,
- intervalo de confianza (bootstrap) del resultado.

Esto convierte el informe estático en una herramienta de decisión *viva*: cualquier propuesta de reasignación se puede probar antes de ejecutar.

7.5 Despliegue técnico

DECISIÓN TÉCNICA

Stack: Streamlit (framework web) + Plotly (gráficos) + scikit-learn (modelo). El dashboard carga los artefactos producidos por el pipeline (`elastic_net.pkl`, `adstock_params.pkl`, `scalers.pkl`) y reconstruye la simulación desde ellos. Cualquier mejora del modelo se refleja en el dashboard sin tocar la capa de presentación.

8 | Conclusiones y recomendaciones

Hay un claro ganador (**Propios y Exterior**, ROI 25.7×) y un claro saturado (**Performance**, ROI 6.0×). La recomendación operativa es implementar la reasignación DO SOMETHING — transferir el 30 % del presupuesto de Performance a Propios y Exterior — en el próximo ejercicio.

8.1 Respuestas a las preguntas de negocio

¿Qué % de las ventas viene del marketing?

Según el modelo, el marketing explica el **91.8 %** de las 758.1 M€ vendidas entre 2020 y 2024 — pero esta cifra debe leerse como un *contrafactual* ("qué pasaría si apagáramos todos los canales"), no como una atribución literal. Parte de lo que el modelo atribuye a medios es, casi con seguridad, memoria de marca acumulada antes de 2020 que no aparece en los datos. En términos *relativos* entre grupos el orden sí es interpretable y robusto.

¿Dónde conviene invertir el próximo euro?

En **Propios y Exterior** (email CRM + exterior). Hoy es el grupo con mayor ROI (25.7×) y el que menos presupuesto absoluto recibe (10.0 M€ sobre 58.9 M€ totales). Las curvas de respuesta confirman que sigue en zona de crecimiento. En paralelo, **Performance** (paid search + social paid) es el grupo saturado: recibe 23.5 M€ (el 40 % del presupuesto) para generar el ROI más bajo (6.0×).

¿Cuánto me fío del modelo?

- R^2 test = 0.65 y MAPE test = 12.2 % — en rango sano para un MMM.
- Test placebo con ΔR^2 = +0.535 → la señal de medios es necesaria, no es ruido.
- IC 95 % *bootstrap* de los cuatro grupos de marketing no cruzan cero.
- Tornado de sensibilidad: errores del $\pm 20\,\%$ en β no invierten la ordenación de ROIs.

8.2 Recomendaciones accionables

1. **Aprobar DO SOMETHING** para el próximo ejercicio: transferir el 30 % del presupuesto de Performance a Propios y Exterior, sin aumentar el gasto total. Los detalles numéricos del *lift* proyectado se pueden consultar en vivo en el dashboard (pestaña *Laboratorio de Inversión*).
2. **No ejecutar DO THE MOST** sin pilotar antes. Reasignar el 60 % concentra demasiado riesgo en Propios y Exterior; el incremento marginal sobre DO SOMETHING no justifica la exposición.
3. **Pilotar reducciones adicionales de Performance** en semanas valle. La curva de respuesta muestra que el grupo está saturado: apagar una semana de paid search rara vez mueve la aguja.
4. **Invertir en capacidad de medición de Propios y Exterior**. Si el grupo va a recibir más presupuesto, el CMO necesita métricas propias (listas CRM segmentadas, paneles de exposición exterior) que permitan validar el *lift* real, no solo el estimado.
5. **Monitorizar trimestralmente** la desviación real vs. proyectada. Si el *lift* se materializa, extender la reasignación un 5–$10\,\%$ más; si no, reentrenar el modelo con los nuevos datos.

6. **Mantener el dashboard vivo.** Que el comité siga usando el simulador antes de cada decisión presupuestaria importante — el valor del proyecto está en la capacidad de *explorar*, no solo en esta recomendación puntual.

8.3 Limitaciones y siguientes pasos

- **Atribución inflada por inercia de marca.** El 91.8 % atribuido a medios captura también la memoria anterior a 2020. Un MMM bayesiano con prior sobre la base orgánica corregiría este efecto.
- **Horizonte corto:** 258 semanas es suficiente para detectar estacionalidad y tendencia, pero limita la identificación de α por grupo (de ahí que los fijemos con priors).
- **Granularidad nacional:** se pierde el detalle ciudad a ciudad. Un modelo jerárquico con efectos por ciudad es el siguiente paso natural si se quiere optimizar el mix local.
- **Efectos cruzados:** el modelo asume independencia entre grupos tras el adstock. Un modelo con interacciones explícitas (p. ej., *Offline Medios* $\times$ *Performance*) podría capturar sinergias, a coste de más parámetros y menos interpretabilidad.
- **Validación causal:** el siguiente paso ideal es complementar el MMM con experimentos controlados (*geo lift* o *conversion lift studies*) que confirmen causalmente las atribuciones estimadas — especialmente en Propios y Exterior antes de aumentar significativamente su peso.

8.4 Cierre

KEY TAKEAWAY

Este informe presenta un **Marketing Mix Model completo y defendible** para K-Moda, construido a partir de 258 semanas de datos históricos y expuesto a través de un dashboard que permite al comité tomar decisiones de reasignación con evidencia. El modelo no es perfecto — ningún MMM lo es — pero es útil, transparente y reproducible. Y la recomendación operativa es clara: *reasignar antes de aumentar, y empezar por mover dinero de Performance a Propios y Exterior*.

Alejandro Barreche Ruiz
UAX · Inteligencia Artificial · Prof. Jacinto